ПолярТех
Ассистент на Graph RAG

Отчёт о реализации и проверках • 9 ноября 2026

Репозиторий команды: github.com/Mihail-mm/llm-project
Ветка: knowledge-graph-from-documents. Основа: 0256cea43faa.

Статус: программная часть реализована и проверена тестами. Это предварительная версия отчёта: метрики реальной LLM не измерены. Для сдачи требуется выполнить прогоны, заполнить результаты и подтвердить сведения о команде. Результаты FakeLLM не выдаются за качество Qwen3.

1. Задача сервисной службы

Диспетчеру нужно пройти от модели оборудования и ошибки к отказавшему узлу, исходной детали и её актуальной замене, затем получить цену и остаток из ERP. Плоский поиск может найти руководство с исходной деталью, но пропустить отдельный бюллетень о снятии с производства.

Пример: E-17 на AR-210 ведёт к пусковому реле P-1042, а сервисный бюллетень указывает замену P-1042B. Граф сохраняет этот переход и документы, из которых он получен.

2. Реализованное решение

Модуль	Решение и проверяемое поведение
Извлечение / FR-1	Строгая JSON-схема, пример направлений, повтор после ошибки, нормализация кодов, словарь имён, фильтр неподтверждённых концов и счётчик dropped.
Граф / FR-2	DiGraph; уникальные чанки в sources и весах; проверка типов; встречные замены разрешаются по весу, при равенстве удаляются обе.
Сообщества / FR-3	Взвешенный Louvain, seed=7; устойчивый порядок узлов; частоты по моделям и линейкам считает код; сводка ограничена 150 словами.
Поиск / FR-4, 5, 10	Пути до трёх связей, окрестность до двух, цепочки замен, поставщик актуальной детали; контекст до 8000 знаков; map/reduce и источники полезных сводок.
Агент / FR-6..10	Пять инструментов, строгие аргументы, проверка детали и количества, кеш вызовов, до трёх попыток ERP, подтверждение заказа и проверка финальных фактов.

3. Результаты проверок

Проверка	Результат
Исходный комплект	142 passed; в том числе все 50 контрактных тестов.
Дополнительные сценарии	40 passed. Суммарно 182 passed, 0 failed. Включена сквозная проверка индекса, сохранения/загрузки JSON и дискового кеша LLMClient с подставным HTTP-ответом.
Стиль и корректность diff	ruff check .: All checks passed!; git diff --check без ошибок.
Интеграция с ERP	Настоящее приложение FastAPI через TestClient: остаток 3 шт. и цена 2630 руб. для P-1042B; без подтверждения заказа нет; повтор подтверждённого вызова не создаёт дубликат.

Среда проверки: Windows, Python 3.12, pytest 8.4.2, NetworkX 3.7, Pydantic 2.14.3, HTTPX 0.28.1, Ruff 0.17.4. В автоматических сценариях ответы модели задаёт FakeLLM. Проверяется логика программы и контракт с ERP, а не способность языковой модели извлекать факты.

Качество ответов на 24 вопросах

Все ячейки «н/д» означают «не измерено», а не нулевое качество. Ни Ollama на localhost:11434, ни другой адрес модели не были доступны; пользователь подтвердил отсутствие готового сервиса.

Режим	local	multihop	global	tool	refusal
baseline	н/д	н/д	н/д	н/д	н/д
local	н/д	н/д	н/д	н/д	н/д
global	н/д	н/д	н/д	н/д	н/д
agent	н/д	н/д	н/д	н/д	н/д

Режим	Recall источников	Выдуманные факты	Вызовов / вопрос	Токенов / вопрос
baseline	н/д	н/д	н/д	н/д
local	н/д	н/д	н/д	н/д
global	н/д	н/д	н/д	н/д
agent	н/д	н/д	н/д	н/д

Извлечение и индексация: Precision и Recall по сущностям и связям, число узлов и рёбер на полном корпусе, стоимость индексации в вызовах и токенах также не измерены. Целевая модель из ТЗ: qwen3:4b-instruct-2507-q4_K_M; эмбеддинги: bge-m3. Ориентир baseline около 0,50 из README не является результатом этого запуска.

4. Где граф помогает и где уступает

Цепочка замены - преимущество графа. В сценарии с BZ-110 путь от узла «нагреватель оттайки» продолжается P-2054 → P-2054B → P-2054C. Дополнительный тест проверяет обе связи замены, переход к поставщику последней детали и сохранение конечного кода в ответе. Сравнение с реальным baseline пока не выполнено: это проверка механизма поиска на заданном графе.

Свободный текст регламента - ограничение графа. Документ procedure_SP-115.md описывает плановую чистку и норму 60 минут, но не связан с кодом ошибки. По эталону его извлечение пустое. При вопросе о порядке такой чистки Graph RAG может отказать из-за отсутствия фактов; плоский RAG имеет доступ к исходному тексту. Это вывод из схемы данных, а не измеренное превосходство baseline.

5. Ошибки и их локализация

Этап / сценарий	Что происходит и как обработано
Извлечение: повреждённый JSON	Неполная структура не превращается в граф. Выполняется одна повторная попытка; после второй ошибки результат пустой. Сценарий проверен контрактом и регрессионным тестом.
Граф: противоречивая замена	При равных весах встречных REPLACED_BY обе связи удаляются. Это снижает полноту ответа, но не выбирает направление наугад. Цикл из трёх деталей приводит к отказу поиска.
Планирование: выдуманная деталь	Код из ошибочного сообщения инструмента не даёт разрешения на следующий вызов ERP. Модель получает ошибку и указание выполнить поиск знаний.
Ответ: неверная цена или остаток	Цифры кода детали не служат доказательством цены. Цена и остаток проверяются по разным полям; допускаются пробелы разрядов и десятичная запятая. Одна коррекция, затем отказ.
ERP: недоступность	Три неудачные попытки дают шаг с error и явное сообщение о недоступности. Это не подменяется отсутствием записи или нулевым остатком.

Это воспроизведённые сценарии отказов и ограничения реализации. Для окончательной сдачи нужно дополнить раздел минимум тремя ошибками реального прогона: вопрос, ответ, источник и этап возникновения.

Оставшиеся ограничения

Сводки могут потерять факты при ограничении 150 слов; контекст local ограничен 8000 знаками. Схема подтверждает наличие кодов и чисел, но не доказывает каждое смысловое утверждение модели. Для заказов кеш защищает от дубля внутри одного запуска. ERP не имеет ключа идемпотентности, поэтому потерянный ответ после записи и повторы между запусками требуют доработки платформы.

6. Границы и подтверждение человеком

Перед созданием заказа код проверяет деталь, склад, модель и положительное целое количество. Количество берётся только из вопроса, а не из предположения модели. При confirm=False выполнение останавливается с needs_confirmation=True и pending_action. Невалидное действие не предлагается к подтверждению. При confirm=True заказ выполняется, и номер заказа включается в ответ.

Все исходные файлы платформы, схемы, данные, существующие тесты и сигнатуры функций сохранены. Вспомогательные функции и дополнительные тесты размещены только в двух разрешённых пакетах. Новых зависимостей в ядре нет; генерация этого PDF выполнена отдельно через ReportLab.

7. Следующий проверяемый шаг

Гипотеза: после отказа local по запросу о свободном тексте регламента запуск плоского поиска повысит полноту ответов без роста доли выдуманных фактов. Проверка: отдельный набор вопросов о шагах и времени ремонта; сравнить accuracy, source_recall и fabricated_rate до и после изменения, не используя этот набор для настройки запросов.

Как завершить воспроизводимый прогон

Запустить Ollama и загрузить две модели из docs/setup.md; затем из корня проекта выполнить команды README. На Windows make запускается через WSL. В .env выбрать адрес модели по способу запуска.

```
make up
make index
make test
make lint
make eval-all
make eval-extraction
```

Дополнительные тесты: **python -m pytest -q src/assistant/graphrag src/assistant/agent**. Основной комплект остаётся доступен через make test.

После прогона требуются graph.json, communities.json, index_stats.json, пять eval_*.json и llm_cache/. Сейчас сохранён только честный протокол проверок artifacts/validation.json. После внесения измерений в отчёт и проверки вклада участников следует сделать коммит сдачи и метку v1.0. Эта метка в ходе текущей работы не создавалась.

8. Вклад участников

Работа выполнена в контексте репозитория GitHub-пользователя Mihail-mm. Реализацию шести модулей, вспомогательных функций, дополнительных тестов и предварительного отчёта подготовил Codex по запросу пользователя. Имена участников и распределение человеческого вклада не предоставлены; их необходимо указать перед защитой. Автоматическая работа не приписана участникам команды.

9. Использование ИИ-инструментов

Codex использован для чтения ТЗ и кода, реализации, проверки требований, запуска тестов и подготовки отчёта. GitHub-коннектор использован для чтения текущего PR и README. FakeLLM использован только в автоматических тестах. Модели Qwen3 и bge-m3 в этой сессии не запускались.